二阶曲率4 二阶泰勒展开 logit空间 - 概率空间 - 损失函数

（参数扰动 → logit → 概率/损失；再到 Hessian / GGN / Fisher 的统一）

---

1. 0. 全局图景（先把地图挂起来）

我们将围绕二阶泰勒展开把上面四层接成一条可计算的链，并在“二阶项”处对比 **Hessian / GGN / Fisher**。

---

2. 1. 记号与最小背景

- $\theta \in \mathbb{R}^p$：全部模型参数；$\Delta\theta$：其小扰动。
- $z(\theta) \in \mathbb{R}^C$：logits；

  $J_z := \partial z / \partial \theta \in \mathbb{R}^{C\times p}$（雅可比）。

  $\mathcal{H}_z := \{\nabla_\theta^2 z_k\}_{k=1}^C$：每个 logit 的参数 Hessian 组成的张量； $\mathcal{H}_z[\Delta\theta, \Delta\theta] \in \mathbb{R}^C$：其对 $(\Delta\theta, \Delta\theta)$ 的双线性作用。
- 损失 $L(y, z)$ 对 z 的一/二阶：
  $g_z := \partial L / \partial z \in \mathbb{R}^C$，

  $H_L := \nabla_z^2 L \in \mathbb{R}^{C\times C}$。
- 余项控制：若 $\nabla^3 z, \nabla^2 L$ 在邻域有界，则泰勒余项为 $O(\|\Delta\theta\|^3)$。

---

3. 2. 第一步： 参数扰动 $\Rightarrow$ logit 变化（二阶泰勒）

对小步长 $\Delta\theta$：

$$\boxed{z(\theta+\Delta\theta)\ \approx\ z(\theta)\ +\ J_z\,\Delta\theta\ +\ \tfrac{1}{2}\,\mathcal{H}_z[\Delta\theta,\Delta\theta].}$$

- 一阶项 $J_z\Delta\theta$：参数对 logit 的线性敏感度。
- 二阶项 $\frac{1}{2}\mathcal{H}_z[\Delta\theta,\Delta\theta]$：模型在参数上的非线性曲率修正。

> 直觉：如果把网络在当前点线性化，就只剩 $J_z\Delta\theta$；保留 $\mathcal{H}_z$ 才能捕捉“网络本身的弯曲”。

4. 3. 第二步：logit 变化 $\Rightarrow$ 损失变化（二阶泰勒）

损失对 z 做二阶泰勒展开

$\Delta L\ \approx\ g_z^\top\Delta z\ +\ \frac{1}{2}\,\Delta z^\top H_L\,\Delta z.$

把 Δz 用上一步替换，并只保留总二阶（二次项里取 $\Delta z\approx J_z\Delta\theta$ 即可）：

$$\Delta L\ \approx\ \underbrace{g_z^\top J_z\,\Delta\theta}_{\text{一阶}}+\tfrac{1}{2}\underbrace{(J_z\Delta\theta)^\top H_L(J_z\Delta\theta)}_{\text{“损失曲率通道”}}+\tfrac{1}{2}\ \underbrace{g_z^\top\mathcal{H}_z[\Delta\theta,\Delta\theta]}_{\text{模型自身二阶（非线性）}}$$

> 把 Δz 代入并逐项分解与定阶：
>
> ## 5. 1) 线性项 $g_z^\top\Delta z$
>
> $$\begin{aligned} g_z^\top\Delta z &= g_z^\top\Big(J_z\Delta\theta+\tfrac{1}{2}\,\mathcal{H}_z[\Delta\theta,\Delta\theta]\Big)+O(\|\Delta\theta\|^3)\\ &= \underbrace{g_z^\top J_z\Delta\theta}_{O(\|\Delta\theta\|)}\ +\ \underbrace{\tfrac{1}{2}\,g_z^\top\mathcal{H}_z[\Delta\theta,\Delta\theta]}_{O(\|\Delta\theta\|^2)}\ +\ O(\|\Delta\theta\|^3). \end{aligned}$$
>
> 第一项是一阶（$\propto\|\Delta\theta\|$）。
>
> 第二项是二阶（$\propto\|\Delta\theta\|^2$）。
>
> ## 6. 2) 二次项 $\frac{1}{2}\,\Delta z^\top H_L\,\Delta z$
>
> 令 $a:=J_z\Delta\theta=O(\|\Delta\theta\|),\qquad b:=\frac{1}{2}\,\mathcal{H}_z[\Delta\theta,\Delta\theta]=O(\|\Delta\theta\|^2),$
>
> 则 $\Delta z=a+b+O(\|\Delta\theta\|^3).$
>
> 用对称性（$H_L^\top=H_L$）展开：

$$
\begin{aligned}
\tfrac{1}{2}\,\Delta z^\top H_L\,\Delta z &= \tfrac{1}{2}\,(a+b)^\top H_L(a+b) + O(\|\Delta\theta\|^4) \\
&= \tfrac{1}{2}\,\underbrace{a^\top H_L a}_{O(\|\Delta\theta\|^2)} + \underbrace{a^\top H_L b}_{O(\|\Delta\theta\|^3)} + \tfrac{1}{2}\,\underbrace{b^\top H_L b}_{O(\|\Delta\theta\|^4)} \;+\; O(\|\Delta\theta\|^4).
\end{aligned}
$$

- $a^\top H_L a$ 是二阶；
- 交叉项 $a^\top H_L b$ 是三阶（丢弃于“总二阶”近似）；
- $b^\top H_L b$ 是四阶（同样丢弃）。

因此在“只保留总二阶”下：

$$
\tfrac{1}{2}\,\Delta z^\top H_L\,\Delta z \;=\; \tfrac{1}{2}\,(J_z\Delta\theta)^\top H_L(J_z\Delta\theta) \;+\; O(\|\Delta\theta\|^3).
$$

---

7. 3) 汇总得到“只保留总二阶”的最终式

把 1) 与 2) 的保留项合并：

$$
\Delta L \;\approx\; \underbrace{g_z^\top J_z\Delta\theta}_{\text{一阶}} \;+\; \tfrac{1}{2}\,\underbrace{(J_z\Delta\theta)^\top H_L(J_z\Delta\theta)}_{\text{二阶（GN/Fisher 块）}} \;+\; \tfrac{1}{2}\,\underbrace{g_z^\top \mathcal{H}_z[\Delta\theta,\Delta\theta]}_{\text{二阶（模型非线性）}} \;+\; O(\|\Delta\theta\|^3).
$$

这正是我们在正文中给出的式子；也解释了为什么在二次项里可以把 Δz 用 $J_z\Delta\theta$ 近似：因为包含 $\mathcal{H}_z$ 的那一部分在二次型里只会产生三阶及以上的项（交叉项 $a^\top H_L b \sim O(\|\Delta\theta\|^3)$ 与 $b^\top H_L b \sim O(\|\Delta\theta\|^4)$），在“总二阶”近似中应当丢弃。

7.1 备注（等价的微分形式，一行见底）

用二阶复合函数微分公式也可一行得到相同结果：
对复合 $L(z(\theta))$，有

$$
\mathrm{d}L = g_z^\top \mathrm{d}z, \qquad \mathrm{d}^2L = (\mathrm{d}z)^\top H_L\,\mathrm{d}z + g_z^\top \mathrm{d}^2 z.
$$

沿方向 $\Delta\theta$ 代入 $\mathrm{d}z = J_z\Delta\theta$，$\mathrm{d}^2z = \mathcal{H}_z[\Delta\theta,\Delta\theta]$，并取
$\Delta L \approx \mathrm{d}L + \frac{1}{2}\,\mathrm{d}^2L$，即得

$$\Delta L \approx g_z^\top J_z \Delta\theta + \tfrac{1}{2}(J_z\Delta\theta)^\top H_L (J_z\Delta\theta) + \tfrac{1}{2} g_z^\top \mathcal{H}_z[\Delta\theta, \Delta\theta].$$

这与上面的按阶展开完全一致。

由此可读出（在 θ 处）：

$$\boxed{\nabla_\theta L = J_z^\top g_z, \qquad \nabla_\theta^2 L = J_z^\top H_L J_z \;+\; \mathcal{T}, \;\; \mathcal{T}_{ab} = \sum_k (g_z)_k \frac{\partial^2 z_k}{\partial\theta_a \partial\theta_b}.}$$

- $J_z^\top H_L J_z$：**经由 logits 的二阶曲率通道**（正半定，数值稳定）
- $\mathcal{T}$：**网络非线性引起的二阶项**（可能导致 Hessian 不定）

到这里，你已经得到了**最核心的“分解版 Hessian”**：

$$H \;=\; \underbrace{J_z^\top H_L J_z}_{\text{GGN/Fisher 块}} \;+\; \underbrace{\mathcal{T}}_{\text{被 GGN/Fisher 忽略}}.$$

8. 4. 两个常用损失的 H_L（带上直觉）

8.1 4.1 Sigmoid + Bernoulli-CE（多标签/二分类）

- $p = \sigma(z)$;
- $g_z = p - y$;
- $H_L = \mathrm{diag}\big(p \odot (1-p)\big)$（每维最多 $1/4$）。

二阶项上界：

$$\tfrac{1}{2}(J_z\Delta\theta)^\top H_L (J_z\Delta\theta) \le \tfrac{1}{8}\|J_z\Delta\theta\|^2.$$

8.2 4.2 Softmax + 多类-CE（多分类）

- $p = \mathrm{softmax}(z)$;
- $g_z = p - y$;
- $H_L = \mathrm{diag}(p) - pp^\top$（协方差型，$\|H_L\|_2 \le \frac{1}{2}$）。

这两种损失都给出**PSD 的 H_L**，因此 $J_z^\top H_L J_z$ 也 PSD —— 这就是 **GGN/Fisher** 稳定的根源。

9. 5. GGN、Fisher、Hessian：定义—联系—差别

9.1 5.1 GGN（Generalized Gauss–Newton）

定义（对样本/批次取均值）：

$$\boxed{G \;:=\; \mathbb{E}[J_z^\top H_L J_z].}$$

含义：把网络在二次项里线性化（只留 $J_z\Delta\theta$），因此等价于 Hessian 去掉 $\mathcal{T}$。
性质：正半定（PSD）、数值稳健、易做矩阵–向量乘（MvP）。

9.2 5.2 Fisher（分布空间的局部度量）

监督学习用条件模型 $p_\theta(y|x)$，

Fisher：

$$F = \mathbb{E}_x\, \mathbb{E}_{y\sim p_\theta(\cdot|x)}\big[\nabla_\theta \log p_\theta(y|x) \nabla_\theta \log p_\theta(y|x)^\top\big].$$

链式换元到 z-空间：

$$\boxed{F = \mathbb{E}_x\big[J_z^\top\, F_R(z)\, J_z\big]}, \quad F_R(z) = \mathbb{E}_{y\sim r(\cdot|z)}[\nabla_z \log r\, \nabla_z \log r^\top].$$

9.3 5.3 Fisher ≡ GGN 的条件（为什么二者常相等）

若损失是负对数似然 $L(y,z) = -\log r(y|z)$，且 r 属指数族且 z 为自然参数（如 Sigmoid/Bernoulli-CE、Softmax/Multinomial-CE、固定方差高斯/MSE），则

$$\boxed{F_R(z) = H_L(z)} \;\Rightarrow\; \boxed{F = \mathbb{E}[J_z^\top H_L J_z] \;\equiv\; G.}$$

结论：在最常见的分类/回归任务下，**Fisher 与 GGN 完全一致**；二者都是“损失曲率通道”的参数空间表达。

9.4 5.4 与 Hessian 的关系（一句话版）

$$\boxed{H \;=\; G \;+\; \mathcal{T}}$$

- H：最精确，但因 $\mathcal{T}$ 可能不定、更“躁动”。
- G, F：**PSD**、抗噪（无“正负抵消”），适合做稳定的大步更新。
- 驻点附近（$g_z \approx 0$）或网络近似线性时：$\mathcal{T}$ 变小，$G \approx H$。

> 经验 **Fisher**（直接用数据标签外积）$\neq$ 真 Fisher；一般也 $\neq$ GGN。实践中要避免用它替代曲率。

10. 6. 读法与实现：如何用它指导优化

10.1 6.1 一阶项：方向与步幅

$\Delta L \approx g_z^\top J_z \Delta\theta.$

- 若限定 $\|\Delta\theta\| = \eta$，最陡降方向是 $-J_z^\top g_z$（即 $-\nabla_\theta L$）。
- $\|J_z^\top g_z\|$ 大说明“线性项主导”，需要更谨慎的步长/线搜索。

10.2 6.2 二阶项：曲率与信任域

$\frac{1}{2}(J_z\Delta\theta)^\top H_L(J_z\Delta\theta) \;\le\; \frac{1}{2}\|H_L\|\,\|J_z\Delta\theta\|^2.$

- Sigmoid：$\|H_L\| \le 1/4$；Softmax：$\|H_L\| \le 1/2$。
- 结合阻尼/信任域（Tikhonov/Trust-Region），可以安全放大步长（尤其用 G 或 F 时）。

10.3 6.3 计算建议（矩阵–向量乘）

优化时常只需 $Gv = J_z^\top(H_L(J_z v))$：
「一次 JVP（$J_z v$）+ 一次 H_L 逐维缩放 + 一次 VJP（$J_z^\top \cdot$）」即可；用 CG/K-FAC 等可近似解 $(G + \lambda I)\delta = -\nabla L$。

---

11. 7. 常见问答（把坑提前填平）

- **Q：为什么工程上常忽略 $\mathcal{T}$？**
  A：$\mathcal{T}$ 的系数是残差 g_z；靠近最优时 $p \approx y$，它自然变小；同时 $\mathcal{T}$ 让 Hessian 不定、难解，忽略后得到 PSD 的 G/F，稳定性大幅提升。
- **Q：Fisher 与 GGN 什么时候不等价？**
  A：当损失不是 NLL、输出分布不是指数族、或 z 不是自然参数时；此时 $F_R \neq H_L$，只能说两者“相关但不相等”。
- **Q：经验 Fisher 能不能当曲率？**
  A：不可靠。它与真 Fisher/GGN 不等价，容易给出误导的缩放；若要二阶，优先用 GGN 或（条件满足时的）真 Fisher。

---

12. 8. 一页速查（随手可复用）

- **主方程（记住这一行就够用）**

  ΔL ≈ gzTJzΔθ + 12 (JzΔθ)THL(JzΔθ) + 12 gzTHz[Δθ,Δθ] \boxed{\ \Delta L\ \approx\ g_z^{\top}J_z\Delta\theta + \tfrac12\,(J_z\Delta\theta)^{\top}H_L(J_z\Delta\theta)\ +\ \tfrac12\,g_z^{\top}\mathcal H_z[\Delta\theta,\Delta\theta]\ }

$$\Rightarrow \nabla_\theta^2 L = \underbrace{J_z^\top H_L J_z}_{\text{GGN/Fisher}} + \underbrace{\mathcal{T}}_{\text{网络非线性二阶}}.$$

- **Sigmoid-CE**：$g_z = p - y$，$H_L = \mathrm{diag}(p(1-p))$，$\|H_L\| \le 1/4$。
- **Softmax-CE**：$g_z = p - y$，$H_L = \mathrm{diag}(p) - pp^\top$，$\|H_L\| \le 1/2$。
- **GGN 定义**：$G = \mathbb{E}[J_z^\top H_L J_z]$（PSD）。
- **Fisher 定义**：$F = \mathbb{E}_x[J_z^\top F_R(z) J_z]$；若 NLL + 指数族 + z 为自然参数，则 $F_R = H_L \Rightarrow F \equiv G$。
- **Hessian 分解**：$H = G + \mathcal{T}$（$\mathcal{T}$ 使 H 可能不定）。

12.1 结语

把二阶泰勒展开作为中枢，你已经建立了：
参数扰动 ⇒ logit（线性敏感度 + 非线性曲率） ⇒ 损失（二阶近似） 的清晰链路；
并理解了 **Hessian = GGN + 非线性二阶**，以及在常见任务下 **Fisher ≡ GGN**。
从此，你可以在论文与实现里自如切换“参数空间”的二阶法与“分布空间”的自然梯度视角。