理解二阶曲率5 二阶泰勒展开 特征空间-logit空间-概率空间-损失函数

在上一节，我们梳理了 logit空间和概率空间的关系，并且给出了分别定义在权重的Fisher矩阵的定义和定义在特征空间上的fisher信息矩阵。接下来我们更进一步，将整个权重进行拆解为特征提取器部分θ_f和最后的线性分类层，并且希望推导出从特征空间空间与权重空间的关系。

二 统一符号与规范定义

为了比较差别，我们分别给出三种不同的泰勒展开

一些通用的符号如下

损失函数为 $L(\hat{p}, y)$, 经过分解的模型处理过程为

$$e = f(x;\theta_f), z = f(e;\theta_c) = W_c e, p = P(z)$$

这里的函数P可以是softmax函数或者sigma函数，保持维度不变但能将输出进行归一化且满足概率的要求

合并在一起可以表示为

$$\hat{p} = \text{softmax}(f(f(x;\theta_f);\theta_c)) = \text{softmax}(W_c \cdot f(x;\theta_f))$$

对应的损失函数可以表示为

$$L = L(p, y) = L(\text{softmax}(W_c \cdot f(x;\theta_f)), y)$$

对于固定的输入(x, y) , L 的大小是由内部的所有参数 $\theta = \{\theta_f, W_c\}$决定的，

对于固定的模型，输出是由输入x 决定的，更近一步也可以看做是z决定的，甚至可以表示为由e决定

- 参数分块：$\theta = (\theta_f, W_c)$，

- 特征抽取：$e = f(x;\theta_f) \in \mathbb{R}^d$，雅可比 $J_e = \partial e/\partial\theta_f \in \mathbb{R}^{d\times|\theta_f|}$，二阶张量 $\mathcal{H}_e = \{\nabla^2_{\theta_f} e_k\}_{k=1}^d$ 。
- 线性头：$z = W_c\, e \in \mathbb{R}^C$。。
- 概率映射：$p = P(z)$（softmax 或逐维 sigmoid；保维度）。
- 损失：$L = L(p,y) = L(P(z),y)$。

- 损失作为 z 的函数，损失在 z-空间的一/二阶：

$$g_z := \frac{\partial L}{\partial z} \in \mathbb{R}^C, \qquad H_{zz} := \nabla^2_z L \in \mathbb{R}^{C\times C}.$$

  - softmax+CE：$g_z = p - y$，$H_{zz} = \mathrm{diag}(p) - pp^\top$；
  - sigmoid+CE：$g_z = p - y$，$H_{zz} = \mathrm{diag}(p \odot (1-p))$

- 对输出作为 θ 的函数，网络的一/二阶：

$$J_z := \frac{\partial z}{\partial\theta} \in \mathbb{R}^{C\times p}, \qquad \mathcal{H}_z = \{\nabla^2_\theta z_k\}_{k=1}^C \text{ (二阶张量)}.$$

  对特征层再细化：

$$J_e := \frac{\partial e}{\partial\theta_f} \in \mathbb{R}^{d\times|\theta_f|},\ \mathcal{H}_e := \{\nabla^2_{\theta_f} e_k\}_{k=1}^d$$

  对线性分类层再细化

  定义作用在增量 $\Delta W \in \mathbb{R}^{C\times d}$ 上的线性算子

$$J_{z,W}[\Delta W] \ := \ \frac{\partial z}{\partial W_c}[\Delta W] \ = \ \Delta W\, e \ \in \ \mathbb{R}^C.$$

  因为 $z = W_c e$ 对 W_c 线性，所以

$$\mathcal{H}_{z,W} \equiv 0 \quad \text{(即 } z \text{ 对 } W_c \text{ 的二阶张量为零)}.$$

> 重要：始终区分 $H_{zz} = \nabla^2_z L$（损失在 logit 空间的 Hessian）与 $\mathcal{H}_z$（logit 对参数的二阶张量）。

三、规范推导（分三段：$\theta \to L$，$\theta \to z \to L$，$e \to z \to L$）

1.1 $\theta \to L$

显然 损失函数是 θ 的函数，对于损失函数我们可以进行泰勒展开

令损失函数 $L : \mathbb{R}^d \to \mathbb{R}$ 在点 θ 处二阶可微，扰动向量 $\Delta\theta \in \mathbb{R}^d$。记

1. $g \;=\; \nabla_\theta L(\theta) \in \mathbb{R}^d.$
2. $H_{\theta\theta} \;=\; \nabla_\theta^2 L(\theta) \in \mathbb{R}^{d\times d}$

则

$$L(\theta+\Delta\theta) \approx L(\theta) + \nabla_\theta L(\theta)^\top \Delta\theta + \tfrac{1}{2}\,\Delta\theta^\top \nabla_\theta^2 L(\theta)_L\,\Delta\theta + R_3(\theta,\Delta\theta)$$

2.2 $\theta \to z \to L$

我们可以对神经网络进行二阶泰勒展开

- $z = z(\theta)$：$\mathrm{d}z = J_z\,\mathrm{d}\theta, \quad \mathrm{d}^2 z = \mathcal{H}_z[\mathrm{d}\theta, \mathrm{d}\theta]$

$$z(\theta+\Delta\theta) \approx z(\theta) + J_z\Delta\theta + \tfrac{1}{2}\,\Delta\theta^\top \mathcal{H}_z \Delta\theta + R_3(\theta,\Delta\theta)$$

将上式变形，我们有

$$\begin{aligned}\Delta z &= z(\theta+\Delta\theta) - z(\theta)\\ &\approx J_z\Delta\theta + \tfrac{1}{2}\,\Delta\theta^\top \mathcal{H}_z\Delta\theta + R_3(\theta,\Delta\theta)\\ &\approx J_z\theta\end{aligned}$$

我们将损失函数在 z-空间进行展开有

- $L = L(z)$：$\mathrm{d}L = g_z^\top \mathrm{d}z, \quad \mathrm{d}^2 L = (\mathrm{d}z)^\top H_{zz}\,\mathrm{d}z$。

$$L(z+\Delta z) \approx L(z) + g_z^T dz + \tfrac{1}{2}\,\Delta z^\top H_{zz}\,\Delta z + R_3(\theta,\Delta\theta)$$

变形有

$$\Delta L \;\approx\; g_z^\top \Delta z \;+\; \tfrac{1}{2}\,\Delta z^\top H_{zz} \Delta z$$

将上面的式子得到的 $\Delta z \approx J_z \Delta\theta$ 带入得到 并只保留总二阶

把 Δz 用上一步替换，并只保留总二阶（二次项里取 $\Delta z \approx J_z \Delta\theta$ 即可）：

$$\Delta L \;\approx\; \underbrace{g_z^\top J_z \Delta\theta}_{\text{一阶}} \;+\; \frac{1}{2}\,\underbrace{(J_z\Delta\theta)^\top H_{zz}(J_z\Delta\theta)}_{\text{GGN/Fisher 块}} \;+\; \frac{1}{2}\,\underbrace{g_z^\top \mathcal{H}_z[\Delta\theta,\Delta\theta]}_{\text{模型非线性二阶}}$$

把 Δz 代入并逐项分解与定阶：

3. 1) 线性项 $g_z^\top \Delta z$

$$\begin{aligned} g_z^\top \Delta z &= g_z^\top \Big(J_z\Delta\theta + \tfrac{1}{2}\,\mathcal{H}_z[\Delta\theta,\Delta\theta]\Big) + O(\|\Delta\theta\|^3) \\ &= \underbrace{g_z^\top J_z \Delta\theta}_{O(\|\Delta\theta\|)} \;+\; \underbrace{\tfrac{1}{2}\, g_z^\top \mathcal{H}_z[\Delta\theta,\Delta\theta]}_{O(\|\Delta\theta\|^2)} \;+\; O(\|\Delta\theta\|^3). \end{aligned}$$

第一项是一阶（$\propto \|\Delta\theta\|$）。

第二项是二阶（$\propto \|\Delta\theta\|^2$）。

4. 2) 二次项 $\frac{1}{2}\,\Delta z^\top H_L\,\Delta z$

令 $a := J_z\Delta\theta = O(\|\Delta\theta\|), \qquad b := \tfrac{1}{2}\,\mathcal{H}_z[\Delta\theta,\Delta\theta] = O(\|\Delta\theta\|^2),$

则 $\Delta z = a + b + O(\|\Delta\theta\|^3)$.

用对称性（$H_L^\top = H_L$）展开：

$$\begin{aligned} \tfrac{1}{2}\,\Delta z^\top H_L\,\Delta z &= \tfrac{1}{2}\,(a+b)^\top H_L (a+b) + O(\|\Delta\theta\|^4) \\ &= \tfrac{1}{2}\,\underbrace{a^\top H_L a}_{O(\|\Delta\theta\|^2)} + \underbrace{a^\top H_L b}_{O(\|\Delta\theta\|^3)} + \tfrac{1}{2}\,\underbrace{b^\top H_L b}_{O(\|\Delta\theta\|^4)} \;+\; O(\|\Delta\theta\|^4). \end{aligned}$$

- $a^\top H_L a$ 是二阶；
- 交叉项 $a^\top H_L b$ 是三阶（丢弃于“总二阶”近似）；
- $b^\top H_L b$ 是四阶（同样丢弃）。

因此在“只保留总二阶”下：

$$\frac{1}{2}\,\Delta z^\top H_L\,\Delta z \;=\; \frac{1}{2}\,(J_z\Delta\theta)^\top H_L(J_z\Delta\theta) \;+\; O(\|\Delta\theta\|^3).$$

---

5. 3) 汇总得到“只保留总二阶”的最终式

把 1) 与 2) 的保留项合并：

$$\Delta L \;\approx\; \underbrace{g_z^\top J_z\Delta\theta}_{\text{一阶}} \;+\; \frac{1}{2}\,\underbrace{(J_z\Delta\theta)^\top H_L(J_z\Delta\theta)}_{\text{二阶（GN/Fisher 块）}} \;+\; \frac{1}{2}\,\underbrace{g_z^\top \mathcal{H}_z[\Delta\theta,\Delta\theta]}_{\text{二阶（模型非线性）}} \;+\; O(\|\Delta\theta\|^3).$$

这正是我们在正文中给出的式子；也解释了为什么在二次项里可以把 Δz 用 $J_z\Delta\theta$ 近似：因为包含 $\mathcal{H}_z$ 的那一部分在二次型里只会产生三阶及以上的项（交叉项 $a^\top H_L b \sim O(\|\Delta\theta\|^3)$ 与 $b^\top H_L b \sim O(\|\Delta\theta\|^4)$），在“总二阶”近似中应当丢弃。

5.1 备注（等价的微分形式，一行见底）

用二阶复合函数微分公式也可一行得到相同结果：
对复合 $L(z(\theta))$，有

$$\mathrm{d}L = g_z^\top \mathrm{d}z, \qquad \mathrm{d}^2L = (\mathrm{d}z)^\top H_L\,\mathrm{d}z + g_z^\top \mathrm{d}^2z.$$

沿方向 $\Delta\theta$ 代入 $\mathrm{d}z = J_z\Delta\theta$，$\mathrm{d}^2z = \mathcal{H}_z[\Delta\theta,\Delta\theta]$，并取 $\Delta L \approx \mathrm{d}L + \frac{1}{2}\,\mathrm{d}^2L$，即得

$$\Delta L \approx g_z^\top J_z\Delta\theta + \frac{1}{2}\,(J_z\Delta\theta)^\top H_L(J_z\Delta\theta) + \frac{1}{2}\,g_z^\top \mathcal{H}_z[\Delta\theta,\Delta\theta].$$

这与上面的按阶展开完全一致。

6.3 拆分模型：$e(\theta_f)$ 与 $z = W_c e$

我们把 (★) 中的 $J_z, \mathcal{H}_z$ 进一步写成特征与线性头的组合。

我们参照上面的思路进行继续拆分 模型内部的关系

我们根据上面的拆分思路，来仔细研究 模型输出z 和损失函数的关系

具体地说，我们将模型里面的特征提取层和线性层进行分开

对于模型，

特征层输入为x 输出为 $e = f(x;\theta_f)$,注意这里的f和上面的f并不一致，为了区别我们可以重新记作$e(x;\theta_f)$

线性分类层，输入为特征e 进行线性变化到 Logit层 $z = W_c e$

得到模型输出后，然后

概率函数将输出从 $z \in \mathbb{R}^C$ 映射到概率 $p \in \mathbb{R}^C$

- 原式：$e = f(x;\theta_f),\ z = W_c e,\ L = L(z)$。
- 微分：$\mathrm{d}e = J_e\,\mathrm{d}\theta_f,\ \mathrm{d}^2 e = \mathcal{H}_e[\mathrm{d}\theta_f, \mathrm{d}\theta_f]$；
  $\mathrm{d}z = W_c\,\mathrm{d}e,\ \mathrm{d}^2 z = W_c\,\mathrm{d}^2 e$。

我们可以对特征提取器进行二阶泰勒展开

$$e(\theta_f + \Delta\theta_f) \approx e(\theta_f) + J_e \Delta\theta_f + \tfrac{1}{2}\mathcal{H}_e[\mathrm{d}\theta_f, \mathrm{d}\theta_f]$$

这样我们就得到了再扰动下 特征的变化

$$\begin{aligned}\Delta e &= e(\theta_f + \Delta\theta_f) - e(\theta_f)\\ &\approx J_e \Delta\theta_f + \tfrac{1}{2}\mathcal{H}_e[\mathrm{d}\theta_f, \mathrm{d}\theta_f]\end{aligned}$$

1 如果我们假定 线性映射层不变，则，这个扰动会继续向前传到，于是有将de, d^2e带入于是有

$$\Delta z \approx W_c J_e \Delta\theta_f + \tfrac{1}{2}\,W_c\,\mathcal{H}_e[\Delta\theta_f, \Delta\theta_f]$$

同样的，我们将损失函数在 z-空间进行展开有

- $L = L(z)$：$\mathrm{d}L = g_z^\top \mathrm{d}z, \quad \mathrm{d}^2 L = (\mathrm{d}z)^\top H_{zz}\,\mathrm{d}z$。

$$L(z + \Delta z) \approx L(z) + g_z \Delta z + \tfrac{1}{2}\,\Delta\theta^\top H_{zz}\,\Delta\theta + R_3(\theta, \Delta\theta)$$

变形有

$$\Delta L \;\approx\; g_z^\top \Delta z \;+\; \tfrac{1}{2}\,\Delta z^\top H_{zz}\Delta z$$

将上面的式子得到的 $\Delta z \approx W_c J_e \Delta\theta_f$ 带入得到 并只保留总二阶

$$\Delta L \approx (W_c^\top g_z)^\top J_e\Delta\theta_f + \tfrac{1}{2}\,(J_e\Delta\theta_f)^\top \underbrace{(W_c^\top H_{zz} W_c)}_{=:F_e}(J_e\Delta\theta_f) + \tfrac{1}{2}\,g_z^\top W_c\,\mathcal{H}_e[\Delta\theta_f,\Delta\theta_f]$$

- 梯度：$\dfrac{\partial L}{\partial\theta_f} = J_e^\top W_c^\top g_z$。
- **特征空间 Fisher/GGN**：$F_e = W_c^\top H_{zz} W_c$。
- **参数空间 Fisher/GGN（特征层）**：$F_{\theta_f} = J_e^\top F_e J_e$。
- 最后一项是“**非 GGN**（模型二阶）”修正，工程上常忽略。

2 由于权重展开是包括了全部参数，于是在线性权重层同样有扰动发生

- 原式：$z = W_c e,\ L = L(z)$。
- 微分与二阶微分：$\mathrm{d}z = W_c\,\mathrm{d}e + (\mathrm{d}W_c)e, \qquad \mathrm{d}^2 z = \underbrace{(\mathrm{d}W_c)\,\mathrm{d}e}_{\text{混合二阶}} + \underbrace{W_c\,\mathrm{d}^2 e}_{\text{特征二阶}}.$

由于同时发生了扰动，

$$\begin{aligned}\Delta z &= z(\theta+\Delta\theta) - z(\theta)\\ &\approx \mathrm{d}z + \tfrac{1}{2}\mathrm{d}^2 z\\ &\approx W_c\,\mathrm{d}e + (\mathrm{d}W_c)e + \tfrac{1}{2}\underbrace{(\mathrm{d}W_c)\,\mathrm{d}e}_{\text{混合二阶}} + \underbrace{W_c\,\mathrm{d}^2 e}_{\text{特征二阶}}\end{aligned}$$

我们将de, d^2e带入于是有,并且有$dW_c = \Delta W_c$

Δ 式（总二阶）：

$$\begin{aligned}\Delta z \;\approx\; &\underbrace{W_c J_e\,\Delta\theta_f + \Delta W_c\,e}_{\text{一阶}}\\ &+\; \tfrac{1}{2}\underbrace{\Big[\,\Delta W_c\,(J_e\Delta\theta_f) \;+\; W_c\,\mathcal{H}_e[\Delta\theta_f,\Delta\theta_f]\,\Big]}_{\text{二阶：混合 + 特征}}.\end{aligned}$$

更进一步

代回 $\Delta L \approx g_z^\top \Delta z + \frac{1}{2}\,\Delta z^\top H_{zz}\Delta z$，保留总二阶，得到

$$
\begin{aligned}
\Delta L \;\approx\;& g_z^{\mid}\left(W_c J_e \Delta\theta_f + \Delta W_c\, e\right) \\
&+\; \tfrac{1}{2}\left(W_c J_e \Delta\theta_f + \Delta W_c\, e\right)^{\top} H_{zz}\left(W_c J_e \Delta\theta_f + \Delta W_c\, e\right) \\
&+\; \tfrac{1}{2}\, g_z^{\top}\Big[\; \Delta W_c\,(J_e \Delta\theta_f) \;+\; W_c\,\mathcal{H}_e[\Delta\theta_f, \Delta\theta_f]\;\Big].
\end{aligned}
$$

其中交叉二阶清晰可见：

$$
\underbrace{(\Delta W_c e)^{\top} H_{zz} (W_c J_e \Delta\theta_f)}_{\text{来自二次型}} \quad + \quad \underbrace{\tfrac{1}{2}\, g_z^{\top}\, \Delta W_c (J_e \Delta\theta_f)}_{\text{来自 } \mathrm{d}^2 z}.
$$