基于你提供的论文内容和你所做的精彩推导，我们可以将 Fisher 信息矩阵与你的特征空间分析紧密联系起来，形成一个完整的理论框架。以下是系统性的总结和延伸：

---

1. 一、Fisher 信息矩阵的几何与优化视角

论文中强调：

> 自然梯度下降 可以视为一种使用 **Fisher 信息矩阵** 作为曲率矩阵的二阶优化方法。

其核心公式为：

$$
\tilde{\nabla} h = F^{-1} \nabla h
$$

其中：

- $F = \mathbb{E}_{p(x,y)}[\nabla \log p(y|x;\theta) \nabla \log p(y|x;\theta)^\top]$ 是 Fisher 信息矩阵；
- 在某些条件下（如指数族输出分布），F 等价于 **广义高斯-牛顿矩阵（GGN）**，而 GGN 是 Hessian 的一种近似，且总是半正定。

---

1. 二、Fisher 信息矩阵与特征空间敏感度矩阵 $\mathbf{G}_\theta$ 的等价性

你在推导中定义的：

$$
\mathbf{G}_\theta = \mathbb{E}_x \left[J_\phi(x)^\top E_\phi(x) J_\phi(x) \right]
$$

其中：

- $E_\phi(x) = W (\text{Diag}(p) - pp^\top) W^\top$ 是特征空间的 Fisher 矩阵；
- $J_\phi(x)$ 是特征对参数的 Jacobian。

这正是论文第 9 节中 **Fisher 矩阵的分解形式**：

> 当 $L(y,z) = -\log r(y|z)$ 且 $r(y|z)$ 是指数族分布时，Fisher 矩阵可写为：
> $$
> F = \mathbb{E}_x \left[J_f^\top F_R J_f \right]
> $$
> 其中 F_R 是输出分布的 Fisher 矩阵。

在你的设定中：

- $f(x;\theta) = W^\top \phi(x;\theta)$，因此 $J_f = W^\top J_\phi$；
- $F_R = \text{Diag}(p) - pp^\top$（对于 softmax 输出）；
- 所以：
  $$
  F = \mathbb{E}_x \left[J_\phi^\top W (\text{Diag}(p) - pp^\top) W^\top J_\phi \right] = \mathbf{G}_\theta
  $$

结论：你定义的 $\mathbf{G}_\theta$ 就是 **Fisher 信息矩阵在特征空间的分解形式**。

---

1. 三、Fisher 信息矩阵与预测稳定性

论文第 6 节指出：

> Fisher 矩阵定义了**分布空间的局部度量**：
> $$
> \text{KL}(P(\theta + d\theta) \mid P(\theta)) \approx \frac{1}{2} d\theta^\top F d\theta
> $$

因此：

- F（即 $\mathbf{G}_\theta$）衡量了**参数扰动对输出分布的敏感度**；
- 大的特征值方向是“高风险方向”，微小扰动会导致输出分布剧烈变化；
- 这正是**灾难性遗忘**的根源：新任务的更新方向若与这些高风险方向重合，会破坏旧任务的预测。

---

1. 四、LoRA 子空间与投影 Fisher 矩阵

你在推导中引入：

$$
\mathbf{G}_{\text{LoRA}} = P_{\text{LoRA}}^\top \mathbf{G}_\theta P_{\text{LoRA}}
$$

这正是 **在 LoRA 参数子空间上投影的 Fisher 矩阵**。

论文第 12 节讨论了参数化不变性：

> 只要曲率矩阵满足 (J \zeta^\top B \theta J \zeta = B \gamma)，优化路径在重参数化下是等价的。

因此，即使我们将优化限制在 LoRA 子空间，只要使用该子空间上的 Fisher 矩阵作为曲率矩阵，仍能保持分布空间的几何性质。

---

1. 五、SAM 与 Fisher 平坦化

你在推导中指出：

> SAM 通过压制 (\mathbf{G}_{\text{LoRA}}) 的最大特征值，使得模型对后续更新更鲁棒。

这与论文第 10 节的观点一致：

> 使用 Tikhonov 阻尼或信任域方法（如 SAM）可以控制更新步长，避免在 Fisher 高风险方向上大步更新。

因此：

- SAM 在 LoRA 子空间中寻找平坦区域，即 (\lambda {\max}(\mathbf{G} {\text{LoRA}})) 小的区域；
- 这等价于在分布空间中找到一个局部鲁棒点，使得任何小更新都不会显著改变预测分布。

---

1. 六、理论结论（可用于论文第 5 节）

基于以上分析，我们可以提出以下理论主张：

0.1 主张 1（Fisher 与特征敏感度等价）

在 softmax 输出和线性分类器的条件下，Fisher 信息矩阵 (F) 等价于特征敏感度矩阵 (\mathbf{G} \theta)，即：

[
F = \mathbb{E} x \left[J \phi^\top W (\text{Diag}(p) - pp^\top) W^\top J \phi \right]
]

这建立了参数空间的曲率与特征空间的预测稳定性之间的直接联系。

0.2 主张 2（LoRA 子空间的 Fisher 投影）

将优化限制在 LoRA 子空间等价于使用投影 Fisher 矩阵 (\mathbf{G}_{\text{LoRA}} = P_{\text{LoRA}}^\top F P_{\text{LoRA}}) 作为曲率矩阵。该矩阵控制了在允许的更新方向上对预测分布的最大扰动。

0.3 主张 3（SAM 作为 Fisher 平坦化）

在 LoRA 子空间中应用 SAM 等价于寻找一个参数配置，使得 (\mathbf{G}_{\text{LoRA}}) 的谱范数最小化，从而在分布空间中形成一个局部鲁棒区域，使得后续任务更新不易破坏已有预测。

0.4 主张 4（连续学习的机制解释）

PECL 中 LoRA-only SAM 的有效性源于：

- 限制更新方向（LoRA 子空间）；
- 在该子空间中压制 Fisher 高风险方向（通过 SAM）；
- 从而在**特征空间**中实现**预测平滑性**，而非仅优化损失曲面。

---

1. 七、实验验证建议

- **测量 (\lambda_{\max}(\mathbf{G}_{\text{LoRA}}))**：在训练前后计算该值，验证 SAM 是否真的压制了它；
- **可视化特征敏感度谱**：绘制 (E_\phi(x)) 的特征值分布，观察是否变得更平坦；
- **对比标准 SGD 与 SAM**：在相同 LoRA 设置下，比较两者在连续学习中的遗忘程度与 Fisher 谱的变化。

如果你希望，我可以将这些主张整理成适合放入论文第 5 节的正式理论陈述和推论。

太好了，这一步就是把一切串起来：Fisher → 特征稳定性 → LoRA 子空间 → SAM 为什么真有用。下面我会把这些元素组织成可以直接放进你第5节（机制分析 / representation stability）的理论解释段落，用连续学习语境说清"为什么 LoRA-only + SAM 会让整个模型更稳定、更不遗忘"。

---

1. Fisher 信息矩阵其实就是"特征扰动有多危险"

我们先把你推导出来的矩阵

$$\mathbf{G}_\theta = \mathbb{E}_x \left[J_\phi(x)^\top \, E_\phi(x) \, J_\phi(x) \right]$$

和经典 Fisher 信息矩阵 F 对齐。

在分类模型中，我们写输出为
$f(x;\theta,W) = W^\top \phi(x;\theta)$,
预测分布为 softmax $p(y|x;\theta,W)$，损失是交叉熵。

已知 Fisher 可以写成（对分类模型）

$$F = \mathbb{E}_x \left[\mathbb{E}_{y\sim p(\cdot|x)} \left[\nabla_\theta \log p(y|x;\theta) \nabla_\theta \log p(y|x;\theta)^\top \right] \right],$$

并且在 softmax + 线性头的设定下，这个 Fisher 可以重写为一个"雅可比–特征–雅可比"的分解形式：

$$F = \mathbb{E}_x \left[J_\phi(x)^\top \, W(\mathrm{Diag}(p) - pp^\top) \, W^\top \, J_\phi(x) \right]. \quad \text{:contentReference[oaicite:0]index=0}$$

而你定义的

$$E_\phi(x) = W(\mathrm{Diag}(p) - pp^\top)W^\top,$$

正好是上式里那一块和类别分布相关的局部特征 Fisher。于是我们可以直接得到

$$F = \mathbf{G}_\theta.$$

这点非常关键：

- $\mathbf{G}_\theta$ 不只是一个"手工定义的灵敏度指标"，它实际上**就是 Fisher 信息矩阵**，也就是模型在当前参数附近，输出分布对参数扰动的二阶敏感度的本质刻画。 New Insights and Perspectives o...
- Fisher 在信息几何里正是局部 KL 度量：

  $$\mathrm{KL}(p_{\theta+d} \,\|\, p_\theta) \approx \tfrac{1}{2} d^\top F d.$$

  换句话说，沿着某个方向 d 去动参数，KL 会涨多少，由 $d^\top F d$ 控制。方向上特征值越大，就越"危险"。 New Insights and Perspectives o...

把它翻成直觉：
Fisher 的大特征值方向 = "一推就乱"的方向 = 最容易导致遗忘/漂移的方向。
而 $\lambda_{\max}(F)$ 就是"最脆弱方向"的风险强度。

---

2. LoRA 子空间相当于在 Fisher 上选子块

PECL 下我们没有在全参数上更新，只能更新 LoRA 适配器的低秩增量 ΔW_t。这一点在你的 Lemma（KL(Q_t^full||P_t^full)=KL(Q_t^Δ||P_t^Δ)）里已经形式化了：任务相关的不确定性、学习自由度、PAC-Bayes 复杂度，全都集中在 LoRA 子空间 $\mathcal{W}_t$，而主干权重和历史适配器部分在当前任务是确定量。也就是说：**当前任务真的"在学"的，只是 LoRA 子空间。**

接下来，把 Fisher 投影到 LoRA 子空间。设 LoRA 的可训练方向张成一个低秩子空间，投影矩阵记为 P_{LoRA}。把参数扰动约束为 $\Delta\theta = P_{\text{LoRA}}\alpha$，我们得到局部 KL 敏感度

$$\text{KL} \approx \alpha^\top \underbrace{\left(P_{\text{LoRA}}^\top F\, P_{\text{LoRA}}\right)}_{\mathbf{G}_{\text{LoRA}}} \alpha.$$

也就是说，$\mathbf{G}_{\text{LoRA}}$ 就是 Fisher（也等价于你的 $\mathbf{G}_\theta$）在 LoRA 可更新子空间内的"受限版本"。它回答的具体问题是：

> "如果我只能顺着 LoRA 的方向去改参数，那么哪种方向会最剧烈地改变输出分布（从而最可能破坏旧任务）？"

$\lambda_{\max}(\mathbf{G}_{\text{LoRA}})$ 就是这组允许方向里最糟糕的那个方向的敏感度。

总结一下到目前为止：

- Fisher F 衡量"全模型有多脆"。
- $\mathbf{G}_{\text{LoRA}} = P_{\text{LoRA}}^\top F P_{\text{LoRA}}$ 衡量"LoRA 那部分的脆弱性"。
- 连续学习时，我们只能动 LoRA，所以**真正危险的其实是 $\mathbf{G}_{\text{LoRA}}$ 的谱半径（最大特征值）**，而不是全模型任意方向的谱半径。

这一步直接把"遗忘是哪里发生的"从一个模糊的直觉，变成了一个可计算的对象。

---

3. SAM 在做什么？它在压 Fisher 的谱 —— 但只在 LoRA 里压

现在把 SAM 放进来。

SAM 的训练步骤可以理解为：在更新前，先找一个驻点附近"最坏的小扰动" $\epsilon^{\backslash *}$（沿梯度方向缩放到半径 ρ 球面），然后让模型在 $\theta + \epsilon^{\backslash *}$ 上下降梯度。这等价于逼模型找到一个**对扰动鲁棒的平坦区域**，即在一小团邻域里 loss 都不会突然飙升。已有工作把这种量化为"expected sharpness"，也就是 PAC-Bayesian bound 里的 E-Sh，它等价于对后验噪声下损失涨幅的期望，从贝叶斯角度看，就是后验分布下模型对自己局部扰动的平均脆弱度；从优化角度看，就是"最坏小扰动会让损失涨多少" New Insights and Perspectives o... 。

在我们这里有两点很重要：

1. **我们只对 LoRA 参数应用 SAM。**也就是说，我们只在 LoRA 子空间里寻找"最坏小扰动"（$\epsilon^{\backslash *}$ 也被限制在 LoRA 方向），并要求 loss 对这些扰动都不敏感。
   - 这正是在直接压 $\mathbf{G}_{\text{LoRA}}$ 的谱半径：如果 $\lambda_{\max}(\mathbf{G}_{\text{LoRA}})$ 很大，那么稍微往那个方向一推，KL 就暴涨，loss 也暴涨，SAM 会把这种方向往回压，直到那些方向也变得平坦。
2. 由于 LoRA 子空间是**唯一还在动的部分**（主干和旧任务 LoRA 都冻住了），最终整模型的参数 $W_t = W_{\text{frozen}} + \Delta W_t$ 也只能落在这些"被平坦化的"子空间方向附近。也就是说，虽然 backbone 没有被直接更新，**最终全模型落脚点的曲率却被 LoRA 子空间的平坦性所支配。**

这正好解释了实验里那个看似"反直觉"的现象：

- 我们只训练了极少量 LoRA 参数；
- 但全模型的 Hessian/Fisher 主特征值（$\lambda_{\max}(H)$, $\lambda_{\max}(F)$）也一起下降；

- FAA/AAA 提升，BWT 变得更接近 0。

用我们现在的语言来说，这并不反直觉：

- 因为整模型最终状态就是“冻结干路 + 低秩微调”；
- 如果那低秩方向本身分布在一个 Fisher 谱已经被压平的区域，那么整模型自然就处于一个总体更平坦、对扰动（尤其是未来任务继续调 LoRA）更鲁棒的 basin。 New Insights and Perspectives o...

换句话说：

LoRA-only SAM = 在唯一可动的子空间里做 Fisher 平谱（压掉最大特征值），从而把最终整模型放到一个“未来任务不好破坏”的位置。

4. 这如何反映到特征表征上？

回到你的“特征层解释”。

你推导了：如果我们对特征施加一个小扰动 $\Delta\phi(x)$，模型输出分布的 KL 变化可以用下面的二次型近似来上界：

$$\mathrm{KL}\big(p(y \mid \phi+\Delta\phi)\,\|\,p(y \mid \phi)\big) \approx \Delta\phi^\top E_\phi \Delta\phi, \quad E_\phi = W(\mathrm{Diag}(p) - pp^\top)W^\top.$$

这里 E_ϕ 是一个“局部特征 Fisher”：它告诉我们，沿哪些特征方向扰动会最破坏预测。这个矩阵如果谱很尖（单一主导方向特大），说明模型把判别信息挤压在少数脆弱方向上，稍微动一下这些方向，分布就变了，类边界就塌了，导致旧任务类簇漂移、原型偏移、CKA 不稳定。

然后你又把这个特征扰动和参数扰动联系起来：

$$\Delta\phi \approx J_\phi \Delta\theta,$$

于是

$$\mathrm{KL} \approx \Delta\theta^\top \Big(\mathbb{E}_x[J_\phi^\top E_\phi J_\phi]\Big)\Delta\theta = \Delta\theta^\top \mathbf{G}_\theta \Delta\theta = \Delta\theta^\top F \Delta\theta.$$

两点直接落地在表示层：

1. 如果 $\lambda_{\max}(F)$（也就是 $\lambda_{\max}(\mathbf{G}_\theta)$）被压小，那么任何允许的参数扰动（尤其是来自后续任务微调的扰动）都会在分布层面引起更小的 KL 改变。
   - 也就是：**特征的判别结构不那么容易被后续任务拖走**，前面类的表征不会剧烈扭曲。
   - 对应你实验里的指标：prototype drift 下降、CKA 稳定性提高、feature energy 分布更均匀（有效秩上升）。这表现为每个类的特征云保持得更稳、更分散，而不是沿某个高增益方向被拽走。
2. 如果我们只在 LoRA 子空间压 $\lambda_{\max}(\mathbf{G}_{\mathrm{LoRA}})$，我们其实是在告诉模型：
   - “以后即使你继续在这个子空间上学新任务，你也别朝那些高增益/高破坏方向动，因为那些方向现在已经被 SAM 拉平了。”
   - 结果就是后续任务学到的新判别方向更接近“互补特征”（新的类在特征空间里找新维度）而不是“覆盖旧特征并重写旧边界”。
   - 这就是我们在 IncLoRA、SeqLoRA 等设置下看到的：BWT 绝对值减小（遗忘减轻），且即使在后续任务继续训练，旧类中心仍基本稳定。

总结成一句话：
SAM 在 LoRA 子空间里压 Fisher 的大特征值，等价于把模型推向一种“多方向、均匀、稳定”的特征分配方式，而不是“单一高增益方向吃天下”的方式。结果就是类内稳定（原型不乱漂）、类间分离不被后续任务破坏、CKA 相似性在时间上不崩。

---

5. 回到论文要说的话（可以放进 §5 的机制解释）

把这些点串起来，你可以在第5节说：

1. 我们已经从第4节