太好了，我们现在可以把第五节写成一条非常完整、可落地的“机制链”章节，而不是简单的现象描述。下面我给出一个更加细化、可以直接放进论文里的第五节大纲（含小节标题、每段落的论点、要放的公式/指标、要引用哪张表），并且融合了我们刚刚总结的 Fisher / 特征敏感度视角。你可以基本照抄这个结构去起草正文。

第5节 From Weight-Space Flatness to Feature-Space Robustness

（中文思路名：从权重平坦到特征鲁棒的机制解释）

> 这一节的目标不是再证明“LoRA-only SAM 有效”，而是解释“它为什么有效”。我们把第四节中的权重空间几何（平坦性、Hessian/Fisher 谱下降）映射到特征空间的稳定性（表示能否被后续任务破坏），并展示这个映射可以被量化、被测量、并且和性能提升高度一致。

5.1 现象之后的追问：性能提升到底来自哪里？（动机段）

小节标题建议：5.1 Why does subspace flatness improve continual learning?

写这一段要讲的内容：

- 复述第四节的结论，但不用讲细节数字，只强调事实：
  - 我们已经看到：在仅更新 LoRA 子空间时使用 SAM，会同时降低 sharpness / Hessian / Fisher，并带来更高的 FAA、更低的遗忘（BWT 更接近 0）。
- 但这个结论还有一个关键空白：
  - 这些收益是“分类头变好了”？
  - 还是“特征更稳定了”？
  - 还是“更新对已有任务的破坏变小了”？
- 这一节的目标是回答：**LoRA-only SAM 为什么可以让特征空间本身变得更鲁棒、更稳定？**
- 点出方法论：
  - 我们将给出一个可计算的特征敏感度度量，把“权重平坦”解释为“特征抗扰动”，并用实验证明它确实和线性探针精度、特征一致性等指标对齐（表 [illegible]）。

5.2 预测分布对特征扰动的敏感度：定义特征空间度量

小节标题建议：5.2 Local feature sensitivity as a predictive stability metric

这一段要做三件事：

1. 定义模型分解
   - 回顾模型分解为特征提取器和线性分类头：

     $$f(x;\theta,W) = W^\top \phi(x;\theta), \quad p(y|x) = \mathrm{softmax}(f(x;\theta,W))$$

     其中 $\phi(x;\theta)$ 是 backbone+LoRA 产生的表示，W 是线性头。
2. 定义特征扰动 $\Delta\phi$ 对输出分布的影响
   - 引入我们推导的"局部特征矩阵"：

     $$E_\phi(x) \;=\; W\big(\mathrm{Diag}(p) - pp^\top\big)W^\top$$
   - 给出 KL 近似（这是关键桥梁）：

     $$\mathrm{KL}\big(p(y|\phi{+}\Delta\phi)\,\|\,p(y|\phi)\big) \approx \Delta\phi^\top\, E_\phi(x)\,\Delta\phi$$
   - 解释含义：
     - E_ϕ 给每个"特征方向"一个代价：这个方向一旦被扰动，预测分布会有多大变化。
     - $\lambda_{\max}(E_\phi)$ 大，说明存在一条"高风险方向"：小小改动特征，就能剧烈改变预测。
3. 解释我们将如何用它
   - 我们把 $\mathrm{tr}(E_\phi)$、$\lambda_{\max}(E_\phi)$、以及有效秩（能量是否集中在少数方向）当成"特征层鲁棒性"指标。
   - 这些量会在表2里出现（Feature Energy, effective Rank）。

👉 这一段结束时可以加一个小命题式总结（非正式的"命题1"）：

> **命题1（特征敏感度）**：如果训练方法压低 E_ϕ 的主导方向（降低其最大特征值并提升能量分布的均匀性），则该方法会让表示对扰动更平滑，预测更稳。

5.3 从参数扰动到特征扰动：LoRA 子空间的作用

小节标题建议：5.3 How LoRA updates drive feature changes

**目标：把 LoRA-only 更新跟 $\Delta\phi$ 建立直接连接，解释"为什么只动 LoRA 也会影响全模型几何"。

这一段写的逻辑：

1. 一阶近似（Jacobian 链路）
   - 写出特征对参数的雅可比：

     $$\Delta\phi(x) \approx J_\phi(x)\,\Delta\theta$$

     其中 $J_\phi(x) = \frac{\partial\phi(x;\theta)}{\partial\theta}$。
2. 限制到 LoRA 子空间
   - 我们的训练是"只更新 LoRA 参数"而不是全模型参数，所以 $\Delta\theta$ 实际上是

     $$\Delta\theta = P_{\text{LoRA}}\,\Delta\alpha$$

     其中 P_{LoRA} 表示 LoRA 子空间的投影（stack 了 LoRA A,B 的方向），$\Delta\alpha$ 是可学习系数。
   - 代入得到：

     $$\Delta\phi(x) \approx J_\phi(x)\,P_{\text{LoRA}}\,\Delta\alpha$$
3. 物理解释：
   - $J_\phi P_{\text{LoRA}}$ = "LoRA 参数的一个微小步长会把特征往哪里推"。
   - 如果这个映射的能量太集中（某些方向特别大），那么小小更新 LoRA 也会严重改变特征，破坏旧任务 → 遗忘。
   - 如果我们用一种训练方式（比如 SAM）让这个映射能量更均匀、更小，那意味着：LoRA 再继续学新任务时，不会把已有特征撕裂那么厉害。

👉 这一段可以引出一个非常关键的解释，用来承接第四节：

> 这实际上解释了第四节里的一个"看起来有点反直觉"的现象：虽然我们只在 LoRA 子空间里做 SAM，但全模型的 Hessian / Fisher 谱都下降了。因为 LoRA 子空间本身就是当前唯一还会改变特征的"通道"，我们让这个通道更平滑，全模型在功能上的整体扰动也就变得更小。

5.4 Fisher 视角下的参数 → 特征 → 预测耦合

小节标题建议：5.4 Projected Fisher as the bridge to continual stability

这段是本节的理论中心，建议单独成小节。我们要正式引入 G_θ 和 G_{LoRA}。

这一段应包含的内容：

1. 从 KL 近似推导参数敏感度
   - 把 5.2 和 5.3 串起来：

$$\mathrm{KL} \approx \Delta\phi^\top E_\phi \Delta\phi \approx \Delta\theta^\top \underbrace{\Big(\mathbb{E}_x[J_\phi(x)^\top E_\phi(x) J_\phi(x)]\Big)}_{G_\theta} \Delta\theta$$

   - 定义

$$G_\theta := \mathbb{E}_x\big[J_\phi^\top E_\phi J_\phi\big]$$

   - 解释：G_θ 衡量"参数空间的哪个方向，是预测分布的高敏感方向"。它其实就是 Fisher 信息矩阵（在 softmax + 线性头假设下，这与你查到的 Fisher=GGN 分解是一致的，引用我们内部总结）。
2. 投影到 LoRA 子空间
   - 我们关心的并不是全参数的敏感度，而是"沿 LoRA 子空间的敏感度"：

$$G_{\mathrm{LoRA}} = P_{\mathrm{LoRA}}^\top G_\theta P_{\mathrm{LoRA}}$$

   - 解释含义：
     - 这是"如果我只能改 LoRA，那一步更新会在预测分布上造成多大破坏？"的度量。
     - $\lambda_{\max}(G_{\mathrm{LoRA}})$ 大 = 有一条特别危险的 LoRA 方向，一点点更新就会改变决策分布 → 大遗忘风险。
     - 条件数 $\kappa(G_{\mathrm{LoRA}})$ 大 = LoRA 更新方向非常不均衡，后续任务可能沿高敏感方向走坏了旧任务的判别结构。
3. 引出 SAM 的作用
   - SAM 在 LoRA 子空间内做的是"对最坏方向进行对抗扰动再下降梯度"。
   - 这等价于：显式压制 $\lambda_{\max}(G_{\mathrm{LoRA}})$，让高风险方向被削平。
   - 也就意味着，它主动寻找一个参数区域，使得未来的 LoRA 更新本身也更安全（更新后，旧任务不容易崩）。

👉 这里建议插入一个正式的"命题2（机制桥梁）"或"Proposition 1"：

> **Proposition（LoRA Fisher Stability）**
> 在 softmax 线性头假设下，SAM 在 LoRA 子空间内的优化可以被解释为在直接压低 G_{LoRA} 的主导特征值并改善其条件数。
> 这意味着：模型被推入一个区域，在这个区域内，后续任务的 LoRA 更新不再会强烈扰动已有任务的决策分布。

读者会非常喜欢这一段，因为它把"为什么只做 LoRA-SAM 也能减忘"说成了"我们改变了未来更新的稳定性约束"。

5.5 实证验证：特征鲁棒性指标和 CL 指标是同步改善的

小节标题建议：5.5 Empirical evidence: feature robustness tracks CL performance

这一段就是讲表2。写法建议是“链式解释”，而不是机械读数字。

要讲的点（配合表2）：

1. Fisher / G_LoRA 谱压缩
   - 观察 $\lambda_{\max}(G_{\mathrm{LoRA}})$ 和 cond(G_LoRA) 在普通优化 vs LoRA+SAM 下的变化。
   - 用语言解释：“SAM 把高风险方向压下去了，也把特征敏感度从‘单一脆弱方向’变成了‘更均匀分布’”。
2. Feature energy 更均衡
   - 用 $\mathrm{tr}(E_\phi)$ 和 effective rank/eigval spread 来说明：特征能量不再集中在少数高增益方向。
   - 翻译成直觉话术：“表示不再依赖某个特别脆弱的方向，而是分散编码语义”。
3. 表征稳定性指标改善
   - $\mathrm{CKA}_{\mathrm{stab}}$ 上升（跨任务一致性更高）；
   - Prototype drift 降低（每个类的特征中心不再剧烈飘移）。
   - 解释：“这就是‘忘得少’的表示层信号”。
4. 线性探针性能提升
   - 线性探针 LA 提升，说明 backbone 表征本身变得更通用、更可线性分离，而不是靠最终分类头硬记忆。
   - 把这点和灾忘联系起来：表示越稳 → 后面任务越像“新分类头重用已有表征”而不是“重写整套特征”。

最后一句话要把链路串起来：

> “我们看到的是一条完整的因果链：LoRA-only SAM → G_{LoRA} 变平滑 → 特征能量分布均匀 → 表征在不同任务间更一致、更不漂移 → 线性探针保持高准确率 → 连续学习时遗忘下降、最终精度上升。”

这就是“从权重平坦到特征鲁棒”的实验验证闭环。

5.6 小结：我们给出的机制性解释

小节标题建议：5.6 Summary: a representation-centric view of subspace flatness

这一段是全节总结段（通常 1 段话即可，放在末尾）。它要为后面的讨论/结论节埋钩子。

要点可以写成 3 句话：

1. 我们不再把 LoRA-only SAM 视为“单纯正则化了参数”，而是把它视为“重塑了未来更新会如何扭曲特征”的几何手段。
   - 关键词：future-proofing the representation。
2. 我们给出的 E_ϕ、G_θ、G_{LoRA} 提供了一个可计算的、任务相关的诊断工具：
   - 你不只是在说“flat